Informe de Análisis Exploratorio
COVID-19 en Colombia — Dataset Completo (2020-2023)

Estudiante: Kevin Leonardo Chaparro Reyes
Curso: Machine Learning con PySpark y Docker | 2026-I
Universidad Santo Tomás — Facultad de Estadística
Fecha: 17 de marzo de 2026

Resumen Ejecutivo

Este informe presenta los resultados del análisis exploratorio de datos (EDA) realizado sobre el dataset oficial de casos de COVID-19 en Colombia, publicado por el Instituto Nacional de Salud (INS) y disponible en Kaggle. El análisis fue ejecutado usando PySpark dentro de un entorno Docker reproducible, procesando más de 6.3 millones de registros con 23 variables entre marzo 2020 y diciembre 2023.

Se formularon 3 preguntas de investigación respaldadas por pruebas estadísticas formales (Chi-cuadrado, Mann-Whitney y Kruskal-Wallis), encontrando evidencia significativa de diferencias en la gravedad del COVID-19 según sexo, edad y departamento en Colombia.

Indicador	Valor
Total de registros analizados	6.387.145
Variables del dataset	23 (7 numéricas, 10 categóricas, 6 fechas)
Periodo cubierto	Marzo 2020 - Diciembre 2023
Tasa de casos leves	97.11%
Total fallecidos	143.110 (2.24%)
Edad promedio de fallecidos	68.63 años
Edad promedio de recuperados	39.21 años

1. Descripción del Dataset

El dataset fue publicado originalmente por el Instituto Nacional de Salud de Colombia y contiene el registro oficial de todos los casos de COVID-19 reportados en el país. Cada fila representa un caso único con información demográfica, geográfica, clínica y temporal del paciente.

Variables principales:

Tipo	Variables
Numéricas directas	ID de caso, Edad, Códigos DIVIPOLA, Pertenencia étnica
Categóricas	Sexo, Estado, Tipo de contagio, Ubicación, Recuperado, Tipo de recuperación
Fechas (6)	Reporte, Notificación, Síntomas, Muerte, Diagnóstico, Recuperación

Valores nulos destacados:

Se identificaron patrones de nulos completamente explicables por el contexto: el Código ISO del país (6.38M nulos) solo se llena para casos importados, la Fecha de muerte (6.2M nulos) corresponde a pacientes que se recuperaron, y los nulos en Fecha de inicio de síntomas (505K) corresponden a casos asintomáticos.

2. Estadística Descriptiva

2.1 Variable Edad

Media	Mediana	Desv. Std.	Mínimo	Máximo	IQR	Asimetría	Curtosis
39.98	38	18.47	1	114	26	0.39	-0.21

La distribución de edad es aproximadamente simétrica con una leve cola hacia la derecha, explicada por casos extremos como el de una persona de 114 años. El 50% central de los casos tiene entre 27 y 53 años, correspondiendo a la población económicamente activa de Colombia, probablemente la más expuesta al virus por mayor movilidad.

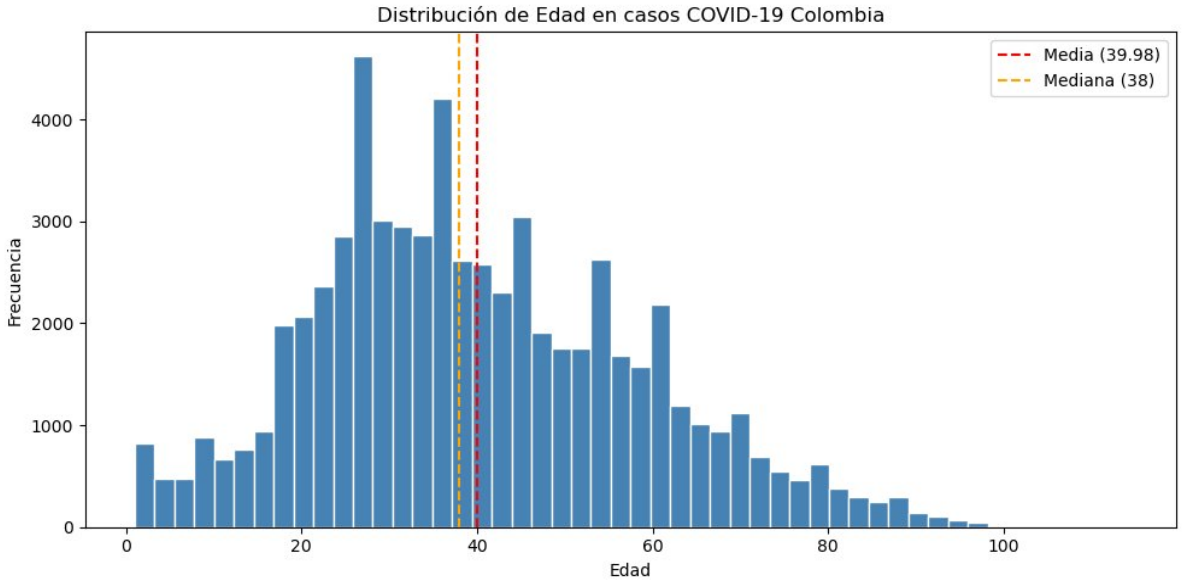

Figura 1. Distribución de edad en casos COVID-19 Colombia. La línea roja indica la media (39.98) y la naranja la mediana (38).

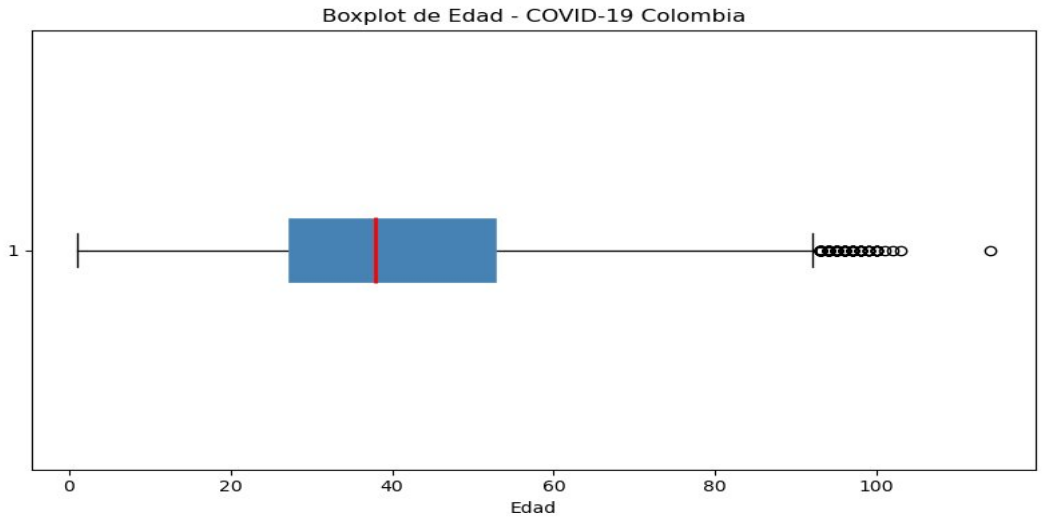

Figura 2. Boxplot de edad. Los puntos a la derecha del límite superior (92 años) son los outliers identificados con criterio IQR.

Se identificaron 14.929 outliers (0.23%) correspondientes a personas mayores de 92 años. Al ser datos reales y clínicamente relevantes, no se eliminaron del análisis.

2.2 Variables Categóricas

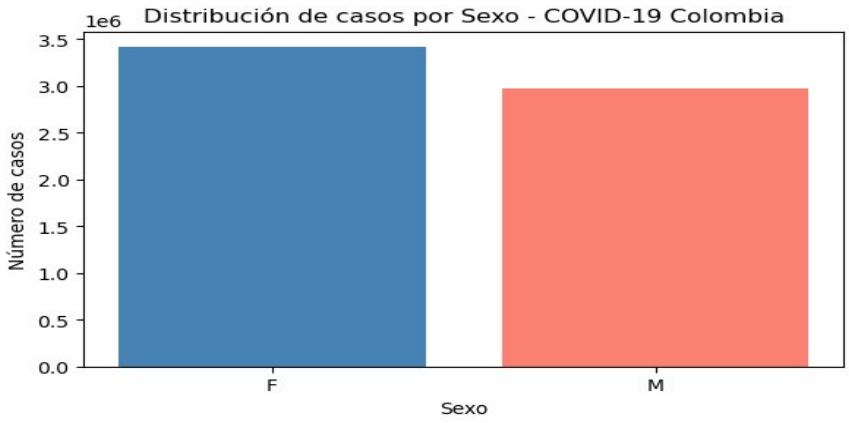

Figura 3. Distribución de casos por sexo. Las mujeres representan el 53.46% y los hombres el 46.54%.

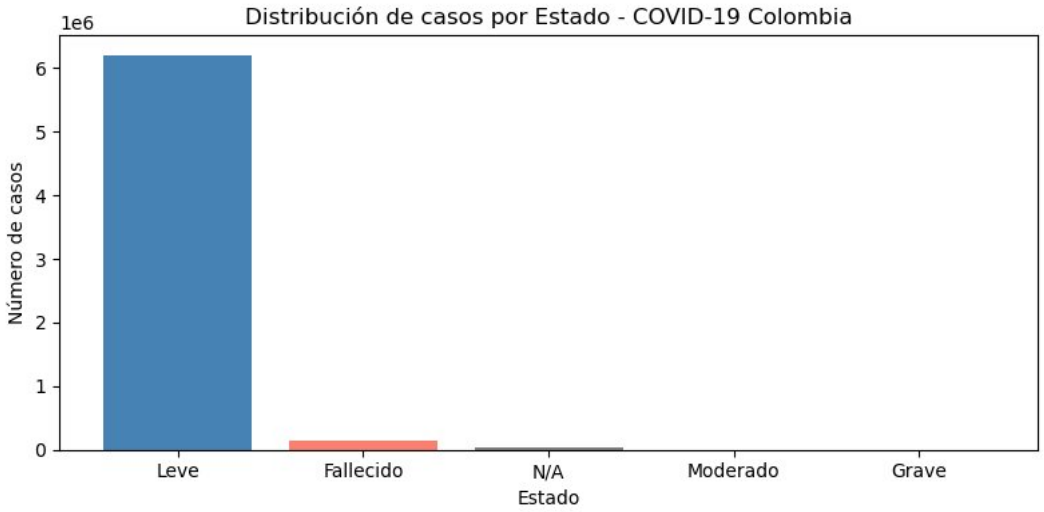

Figura 4. Distribución de casos por estado clínico. El 97.11% de los casos fueron leves.

La figura 4 ilustra de forma contundente que el COVID-19 en Colombia fue principalmente una enfermedad de alta transmisión pero baja mortalidad. Las categorías Moderado y Grave son prácticamente invisibles en la escala, con apenas 395 casos hospitalizados en total.

3. Correlaciones y Relaciones

3.1 Matriz de correlación

Se calculó la matriz de correlación de Pearson entre las variables numéricas directas y las derivadas de las fechas. Las 3 correlaciones más fuertes encontradas fueron:

Par de variables	Correlación	Tipo
mes_reporte vs anio_reporte	-0.68	Negativa fuerte
dias_sintomas_muerte vs mes_reporte	-0.33	Negativa moderada
dias_diagnostico_recuperacion vs anio_reporte	-0.24	Negativa moderada

La correlación más fuerte refleja el comportamiento temporal de la pandemia: al inicio (2020) los casos se concentraron en los últimos meses del año, mientras que en años posteriores se distribuyeron en todos los meses. La reducción en días de recuperación con el paso de los años es consistente con el efecto de la vacunación y mejores protocolos clínicos.

> **Importante: correlacion no implica causalidad. Que los tiempos de recuperacion hayan bajado con los años no significa que el año sea la causa — intervienen factores como la vacunacion, variantes menos agresivas y mejores tratamientos.**

3.2 Relación entre edad y tiempo de recuperación

Grupo de edad	Total casos	Promedio días recuperación
Menor de 18	560.734	13.96 días
18-39	2.864.280	14.61 días
40-59	1.897.642	14.80 días
60-79	761.577	15.79 días
80 o más	119.911	17.80 días

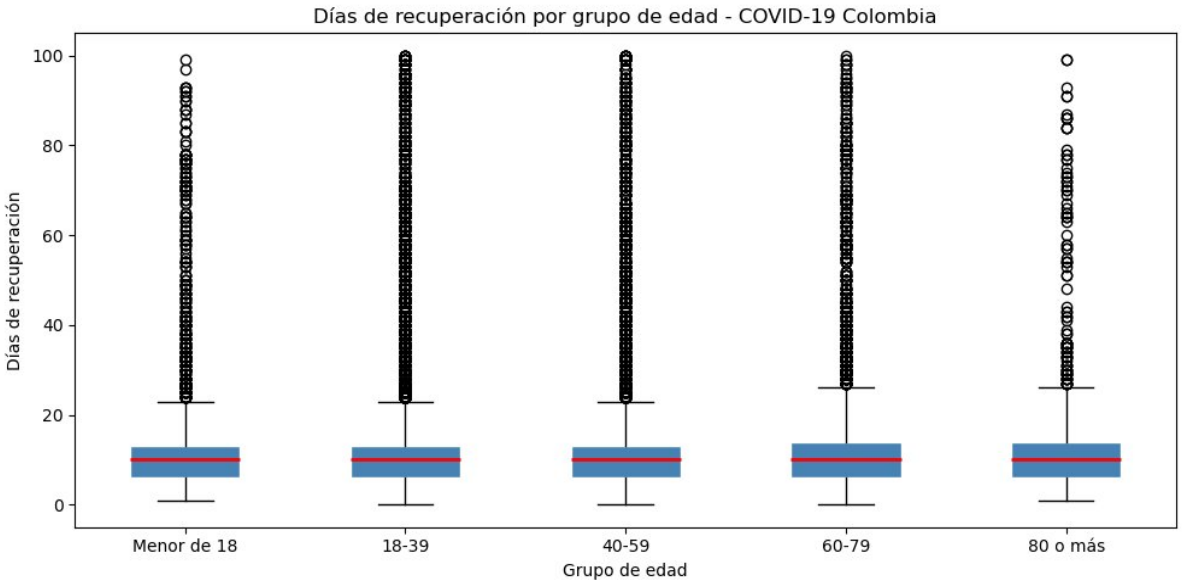

Figura 5. Días de recuperación por grupo de edad. Se observa una tendencia sutil de mayor duración en grupos de mayor edad.

4. Pruebas Estadísticas de Hipótesis

4.1 Normalidad de la variable Edad — Kolmogorov-Smirnov

Se aplicó la prueba KS porque con 6.3 millones de datos la prueba Shapiro-Wilk no es aplicable.

Estadístico KS	P-valor	Nivel de significancia (α)	Conclusión
0.0634	7.49e-225	0.05	Se rechaza H0 — Edad NO es normal

Al no seguir una distribución normal, para comparaciones entre grupos se utilizaron pruebas no paramétricas (Mann-Whitney y Kruskal-Wallis) en lugar de pruebas paramétricas como el T-test.

4.2 Asociación entre Sexo y Gravedad — Chi-cuadrado

Estadístico Chi-cuadrado	Grados de libertad	P-valor	Conclusión
12.842.22	4	≈ 0.0	Se rechaza H0 — Sí hay asociación

Estado	Femenino	Masculino	Tasa fallecidos F	Tasa fallecidos M
Leve	3.339.621	2.862.819	—	—
Fallecido	56.373	86.737	1.65%	2.92%
Grave	13	22	—	—
Moderado	184	176	—	—

La tasa de fallecimiento en hombres (2.92%) fue casi el doble que en mujeres (1.65%), confirmando la hipótesis H1. Esta diferencia es estadísticamente significativa con un nivel de significancia de 0.05.

4.3 Edad en fallecidos vs recuperados — Mann-Whitney

Estadístico Mann-Whitney	P-valor	Edad prom. fallecidos	Edad prom. recuperados
80.494.729	≈ 0.0	68.63 años	39.21 años

La diferencia de casi 30 años entre el promedio de edad de fallecidos y recuperados es estadísticamente significativa. Esto reformula la hipótesis H3: la edad no afectó cuánto tardaban en recuperarse sino la probabilidad de sobrevivir.

4.4 Gravedad por departamento — Kruskal-Wallis

Departamento	Registros muestra	Tasa de fallecidos
Bogotá	93.794	1.62%
Antioquia	47.801	2.00%
Valle del Cauca	28.661	2.73%
Cundinamarca	16.570	2.24%

Santander	14.876	3.00%

Estadístico Kruskal-Wallis: 224.91 | P-valor: 1.65e-47 | Conclusión: Se rechaza H0.

Aunque Bogotá tuvo más casos absolutos, su tasa de fallecidos fue la más baja (1.62%). Santander, con menos casos totales, tuvo la tasa más alta (3.00%). Esto sugiere que el acceso a servicios de salud fue más determinante que la cantidad de casos.

5. Evolución Temporal de la Pandemia

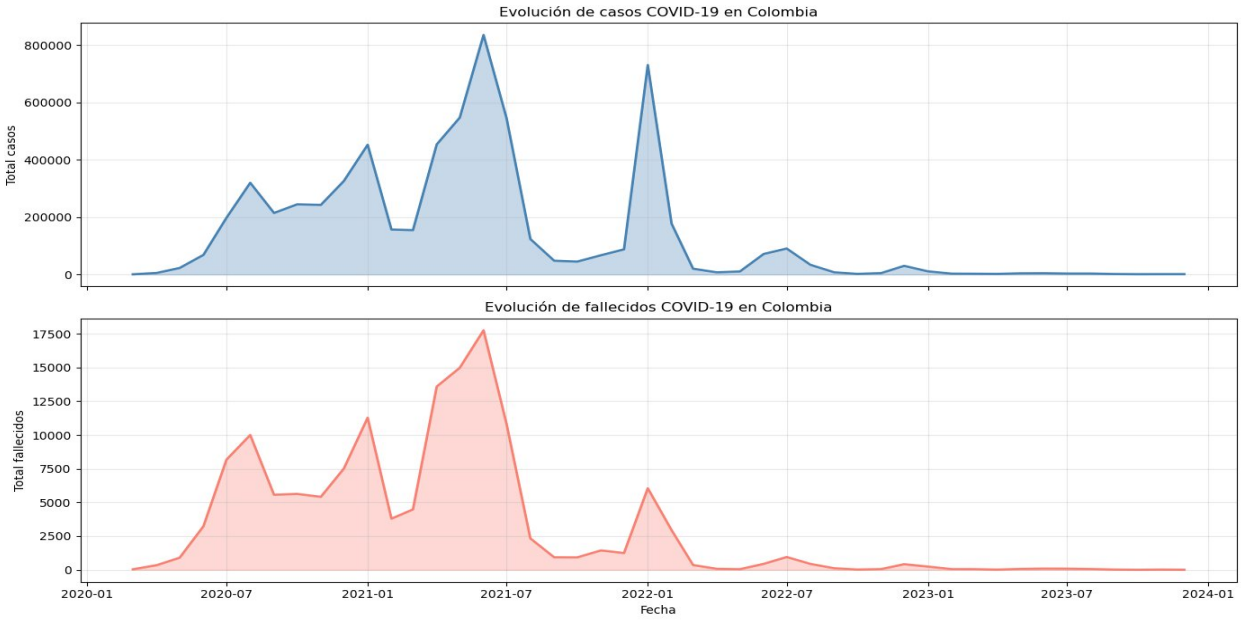

Figura 6. Evolución mensual de casos y fallecidos por COVID-19 en Colombia (2020-2023).

Ola	Periodo	Pico casos/mes	Pico fallecidos/mes	Contexto
1ra	Jul-Ago 2020	~300.000	~10.000	Sin vacunas disponibles
2da	Ene 2021	~450.000	~11.000	Festividades fin de año 2020
3ra	May-Jun 2021	~830.000	~17.500	Ola más letal. Paro Nacional
4ta	Ene 2022	~730.000	~6.200	Alta vacunacion. Menos muertes

La ola 4 es el hallazgo más importante del análisis temporal: a pesar de tener casi tantos casos como la ola 3, los fallecidos fueron menos de la mitad. Esto evidencia el impacto real de la vacunación en Colombia, desacoplando los contagios de las muertes.

6. Conclusiones

6.1 Respuesta a las preguntas de investigación

Pregunta 1: ¿Existe diferencia en la gravedad entre hombres y mujeres?

Sí. La prueba Chi-cuadrado ($p \approx 0$) confirmó una asociación significativa. Los hombres tuvieron una tasa de fallecimiento del 2.92% frente al 1.65% de las mujeres, casi el doble. Hipótesis H1 confirmada.

Pregunta 2: ¿Qué departamentos concentraron más casos graves?

Bogotá, Antioquia y Valle lideraron en números absolutos, pero Santander tuvo la mayor tasa de fallecidos (3.00%) y Bogotá la menor (1.62%). Hipótesis H2 confirmada parcialmente — más casos no implica mayor gravedad relativa.

Pregunta 3: ¿La edad afectó el tiempo de recuperación?

La correlación edad-recuperación fue casi nula (0.02). Sin embargo Mann-Whitney reveló que la edad sí determinó la probabilidad de fallecer (68.63 vs 39.21 años). Hipótesis H3 reformulada: la edad no afectó cuánto tardaban en recuperarse sino si sobrevivían.

6.2 Estado de las hipótesis

Hipótesis	Estado	Prueba utilizada
H1 - Hombres con mayor gravedad	Confirmada	Chi-cuadrado ($p \approx 0$)
H2 - Más población = más casos graves	Parcialmente confirmada	Kruskal-Wallis ($p \approx 0$)
H3 - Mayor edad = más días recuperación	Reformulada	Mann-Whitney ($p \approx 0$)

6.3 Limitaciones

El alto porcentaje de nulos en variables como grupo étnico (6.3M) y la ausencia de datos de vacunación limitaron el alcance del análisis. Además, los casos asintomáticos no detectados por falta de pruebas generan un subregistro difícil de cuantificar, especialmente en 2020.

6.4 Propuestas de análisis futuros

Se propone construir un modelo de clasificación para estimar la probabilidad de fallecimiento según edad, sexo y departamento. También implementar un modelo ARIMA o Prophet sobre la serie temporal para estudiar los patrones de las olas de forma retrospectiva. Finalmente, cruzar este dataset con los datos de vacunación del Ministerio de Salud para cuantificar su impacto real.